

APRENDIZAJE AUTOMÁTICO

Entregable T5: Redes Neuronales Multicapa

Victoria Beltrán Domínguez

vicbeldo@inf.upv.es

Grupo computación: 4CO11

Universitat Politècnica de Valencia

En este trabajo, se pide realizar los siguientes ejercicios:
 1) Escribir el algoritmo BackProp (batch e incremental) con momentum.

ALGORITMO BACKPROP BATCH CON MOMENTUM

Entrada: Topología, pesos iniciales $\theta_{ij}^l(0)$, $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, factor de aprendizaje ρ , condiciones de convergencia, N datos de entrenamiento S, inercia o momentum $0 \leq v < 1$.

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S.

k=1

Mientras no se cumplan las condiciones de convergencia

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, inicializar $\Delta\theta_{ij}^l(k) = 0$

Para cada muestra de entrenamiento $(x, t) \in S$

Desde la capa de entrada a la de salida ($l = 0, \dots, L$):

Para $1 \leq i \leq M_l$:

si $l=0$: $s_i^0 = x_i$

sino: Calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$):

Para cada nodo ($1 \leq i \leq M_l$) calcular:

si $l=L$: $\delta_i^L = g'(\phi_i^L)(t_{ni} - s_i^L)$

sino $\delta_i^l = g'(\phi_i^l)(\sum_r \delta_r^{l+1} \theta_{ri}^{l+1})$

para cada peso θ_{ij}^l ($0 \leq j \leq M_{l-1}$):

calcular: $\Delta\theta_{ij}^l(k) = \Delta\theta_{ij}^l(k) + \rho \delta_i^l s_j^{l-1}$

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, actualizar pesos:

$$\Delta\theta_{ij}^l(k) = \frac{1}{N} \Delta\theta_{ij}^l(k) + v \Delta\theta_{ij}^l(k-1)$$

$$\theta_{ij}^l = \theta_{ij}^l + \Delta\theta_{ij}^l(k)$$

k=k+1

ALGORITMO BACKPROP INCREMENTAL CON MOMENTUM

Entrada: Topología, pesos iniciales $\theta_{ij}^l(0)$, $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, factor de aprendizaje ρ , condiciones de convergencia, N datos de entrenamiento S, inercia o momentum $0 \leq v < 1$.

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S.

k=1

Mientras no se cumplan las condiciones de convergencia

Para cada muestra de entrenamiento (x, t) $\in S$ (en orden aleatorio)

Desde la capa de entrada a la de salida ($l = 0, \dots, L$):

Para $1 \leq i \leq M_l$:

si $l=0$: $s_i^0 = x_i$

sino: Calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$):

Para cada nodo ($1 \leq i \leq M_l$) calcular:

si $l=L$: $\delta_i^L = g'(\phi_i^L)(t_{ni} - s_i^L)$

sino $\delta_i^l = g'(\phi_i^l)(\sum_r \delta_r^{l+1} \theta_{ri}^{l+1})$

para cada peso $\theta_{ij}^l(k)$ ($0 \leq j \leq M_{l-1}$) calcular: $\Delta \theta_{ij}^l(k) = \rho \delta_i^l s_j^{l-1}$

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, actualizar pesos:

$$\Delta \theta_{ij}^l(k) = \frac{1}{N} \Delta \theta_{ij}^l(k) + v \Delta \theta_{ij}^l(k-1)$$

$$\theta_{ij}^l = \theta_{ij}^l + \Delta \theta_{ij}^l(k)$$

k=k+1

2)Escribir el algoritmo BackProp (batch e incremental) con amortiguamiento.

ALGORITMO BACKPROP BATCH CON AMORTIGUAMIENTO

Entrada: Topología, pesos iniciales $\theta_{ij}^l(0)$, $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, factor de aprendizaje ρ , condiciones de convergencia, N datos de entrenamiento S, factor de regularización λ .

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S.

k=1

Mientras no se cumplan las condiciones de convergencia

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, inicializar $\Delta\theta_{ij}^l(k) = 0$

Para cada muestra de entrenamiento $(x, t) \in S$

Desde la capa de entrada a la de salida ($l = 0, \dots, L$):

Para $1 \leq i \leq M_l$:

si $l=0$: $s_i^0 = x_i$

sino: Calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$):

Para cada nodo ($1 \leq i \leq M_l$) calcular:

si $l == L$: $\delta_i^L = g'(\phi_i^L)(t_{ni} - s_i^L)$

sino $\delta_i^l = g'(\phi_i^l)(\sum_r \delta_r^{l+1} \theta_{ri}^{l+1})$

para cada peso $\theta_{ij}^l(k)$ ($0 \leq j \leq M_{l-1}$)

calcular: $\Delta\theta_{ij}^l(k) = \Delta\theta_{ij}^l(k) + \rho \delta_i^l s_j^{l-1}$

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, actualizar pesos:

$$\Delta\theta_{ij}^l(k) = \frac{1}{N} \Delta\theta_{ij}^l(k) + \rho \lambda \Delta\theta_{ij}^l(k-1)$$

$$\theta_{ij}^l = \theta_{ij}^l + \Delta\theta_{ij}^l(k)$$

k=k+1

ALGORITMO BACKPROP INCREMENTAL CON AMORTIGUAMIENTO

Entrada: Topología, pesos iniciales $\theta_{ij}^l(0)$, $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, factor de aprendizaje ρ , condiciones de convergencia, N datos de entrenamiento S, factor de regularización λ .

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S.

k=1

Mientras no se cumplan las condiciones de convergencia

Para cada muestra de entrenamiento (x, t) \in S (en orden aleatorio)

Desde la capa de entrada a la de salida ($l = 0, \dots, L$):

Para $1 \leq i \leq M_l$:

si $l=0$: $s_i^0 = x_i$

sino: Calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$):

Para cada nodo ($1 \leq i \leq M_l$) calcular:

si $l = L$: $\delta_i^L = g'(\phi_i^L)(t_{ni} - s_i^L)$

sino $\delta_i^l = g'(\phi_i^l)(\sum_r \delta_r^{l+1} \theta_{ri}^{l+1})$

para cada peso $\theta_{ij}^l(k)$ ($0 \leq j \leq M_{l-1}$)

calcular: $\Delta\theta_{ij}^l(k) = \rho \delta_i^l s_j^{l-1}$

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, actualizar pesos:

$$\Delta\theta_{ij}^l(k) = \frac{1}{N} \Delta\theta_{ij}^l(k) + \rho \lambda \Delta\theta_{ij}^l(k-1)$$

$$\theta_{ij}^l = \theta_{ij}^l + \Delta\theta_{ij}^l(k)$$

k=k+1

3)Escribir el algoritmo BackProp (batch e incremental) para clasificación.

Para escribir el algoritmo BackProp para clasificación, debemos sustituir la fórmula del error cuadrático por la de la entropía cruzada y derivar para obtener los nuevos parámetros. Las fórmulas de la entropía cruzada son :

$$q_S(\Theta) = -\frac{1}{N} \sum_{n=1}^N q_n(\Theta) \quad q_n(\Theta) = \sum_{i=1}^{M_L} t_{ni} \log s_i^L(x_n; \Theta)$$

Como queremos que la entropía cruzada sea mínima, aplicaremos descenso por gradiente para encontrar las ecuaciones para las capas ocultas y la capa de salida.

Entonces, dada una topología de un perceptrón multicapa con L capas y un conjunto de entrenamiento:

$$S = \{(x_1, t_1), (x_2, t_2), \dots, (x_N, t_N)\}, \quad x_N \in \mathbb{R}^{M_0}, t_n \in \mathbb{R}^{M_L}$$

obtener Θ que minimice la entropía cruzada.

$$\Delta \theta_{ij}^l = -p \frac{\partial q_S(\Theta)}{\partial \theta_{ij}^l} = \frac{1}{N} \sum_{n=1}^N -p \frac{\partial q_n(\Theta)}{\partial \theta_{ij}^l} = \frac{1}{N} \sum_{n=1}^N \Delta_n \theta_{ij}^l$$

Así, debemos calcular para cada muestra:

$$\Delta_n \theta_{ij}^l = -p \frac{\partial q_n(\Theta)}{\partial \theta_{ij}^l}, 1 \leq i \leq M_L, 0 \leq j \leq M_{l-1}, 1 \leq l \leq L, 1 \leq n \leq N$$

Para simplificar pero sin pérdida de generalidad, en lo que sigue se asume L=2. Para las ecuaciones de la capa de salida, la actualización de pesos θ_{ij}^2 para una muestra genérica:

$$q(\Theta) = q_n(\Theta) = \sum_{i=1}^{M_2} t_{ni} \log s_i^L \quad s_i^2 = g(\phi_i^2)$$

$$\phi_i^2 = \sum_{m=0}^{M_1} \theta_{im}^2 s_m^1$$

Entonces, si empezamos a derivar:

$$\frac{\partial q}{\partial \theta_{ij}^2} = \frac{\partial q}{\partial s_i^2} \cdot \frac{ds_i^2}{d\phi_i^2} \cdot \frac{\partial \phi_i^2}{\partial \theta_{ij}^2} = \frac{t_{ni}}{s_i^2} g'(\phi_i^2) s_m^1$$

Así, para la capa de salida (en este caso l=2), las ecuaciones serán:

$$\delta_i^2 = \frac{t_{ni}}{s_i^2} g'(\phi_i^2)$$

$$\Delta_n \theta_{ij}^2 = p \delta_i^2 s_j^1, 1 \leq i \leq M_2, 0 \leq j \leq M_1$$

Para las ecuaciones de las capas ocultas, procederemos de la misma forma para calcular la actualización de pesos θ_{ij}^2 para una muestra genérica:

$$\begin{aligned} q(\Theta) &= q_n(\Theta) = \sum_{i=1}^{M_2} t_{ni} \log s_i^2 & s_i^2 &= g(\phi_i^2) \\ \phi_i^2 &= \sum_{m=0}^{M_1} \theta_{im}^2 s_m^1 & s_m^1 &= g(\phi_m^1) & \phi_m^1 &= \sum_{k=0}^{M_0} \theta_{km}^1 x_k \\ \frac{\partial q}{\partial \theta_{ij}^1} &= \sum_{r=1}^{M_2} \frac{\partial q}{\partial s_r^2} \cdot \frac{\partial s_r^2}{\partial \theta_{ij}^1} = \sum_{r=1}^{M_2} \frac{\partial q}{\partial s_r^2} \cdot \frac{ds_r^2}{d\phi_r^2} \cdot \frac{\partial \phi_r^2}{\partial s_i^1} \cdot \frac{ds_i^1}{d\phi_i^1} \cdot \frac{\partial \phi_i^1}{\partial \theta_{ij}^1} \end{aligned}$$

Resolviendo las derivadas obtenemos los siguientes resultados:

$$\sum_{r=1}^{M_2} \delta_r^2 \theta_{ri}^2 g'(\phi_i^1) x_j = g'(\phi_i^1) x_j \sum_{r=1}^{M_2} \delta_r^2 \theta_{ri}^2$$

Entonces, el error en el nodo i de la capa oculta l se obtiene como:

$$\delta_i^l = g'(\phi_i^l) \sum_{r=1}^{M_l} \delta_r^{l+1} \theta_{ri}^{l+1}$$

Resultando así : $\Delta_n \theta_{ij}^l = p \delta_i^l x_j$

A partir de las ecuaciones obtenidas en el proceso, se procede a escribir el pseudocódigo de batch e incremental.

ALGORITMO BACKPROP BATCH PARA CLASIFICACIÓN

Entrada: Topología, pesos iniciales θ_{ij}^l , $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, factor de aprendizaje ρ , condiciones de convergencia, N datos de entrenamiento S.

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S.

Mientras no se cumplan las condiciones de convergencia

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, inicializar $\Delta\theta_{ij}^l = 0$

Para cada muestra de entrenamiento $(x, t) \in S$

Desde la capa de entrada a la de salida ($l = 0, \dots, L$):

Para $1 \leq i \leq M_l$:

si $l=0$: $s_i^0 = x_i$

sino: Calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$):

Para cada nodo ($1 \leq i \leq M_l$) calcular:

si $l == L$: $\delta_i^l = g'(\phi_i^l) \frac{t_{ni} - s_i^l}{s_i^l}$

sino $\delta_i^l = g'(\phi_i^l) \sum_{r=1}^{M_{l+1}} \delta_r^{l+1} \theta_{ri}^{l+1}$

para cada peso θ_{ij}^l ($0 \leq j \leq M_{l-1}$) calcular: $\Delta\theta_{ij}^l = \delta_i^l + \rho \delta_i^l s_j^{l-1}$

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, actualizar pesos: $\theta_{ij}^l = \theta_{ij}^l + \frac{1}{N} \Delta\theta_{ij}^l$

ALGORITMO BACKPROP INCREMENTAL PARA CLASIFICACIÓN

Entrada: Topología, pesos iniciales θ_{ij}^l , $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, factor de aprendizaje ρ , condiciones de convergencia, N datos de entrenamiento S.

Salidas: Pesos de las conexiones que minimizan el error cuadrático medio de S.

Mientras no se cumplan las condiciones de convergencia

Para cada muestra de entrenamiento $(x, t) \in S$ (en orden aleatorio)

Desde la capa de entrada a la de salida ($l = 0, \dots, L$):

Para $1 \leq i \leq M_l$:

si $l=0$: $s_i^0 = x_i$

sino: Calcular ϕ_i^l y $s_i^l = g(\phi_i^l)$

Desde la capa de salida a la de entrada ($l = L, \dots, 1$):

Para cada nodo ($1 \leq i \leq M_l$) calcular:

si $l=L$: $\delta_i^l = g'(\phi_i^l) \frac{t_{ni} - s_i^l}{s_i^l}$

sino $\delta_i^l = g'(\phi_i^l) \sum_{r=1}^{M_{l+1}} \delta_r^{l+1} \theta_{ri}^{l+1}$

para cada peso θ_{ij}^l ($0 \leq j \leq M_{l-1}$) calcular: $\Delta \theta_{ij}^l = \rho \delta_i^l s_j^{l-1}$

Para $1 \leq l \leq L$, $1 \leq i \leq M_l$, $0 \leq j \leq M_{l-1}$, actualizar pesos: $\theta_{ij}^l = \theta_{ij}^l + \frac{1}{N} \Delta \theta_{ij}^l$